

Домашнее задание по курсу «Введение в машинное обучение»

Задача 1. Рассмотрим функцию, равную косинусу угла между двумя векторами $x, z \in \mathbb{R}^d$:

$$K(x, z) = \cos(\widehat{x, z}).$$

Покажите, что она является ядром.

Задача 2. Рассмотрим следующую функцию на пространстве вещественных чисел:

$$K(x, z) = \frac{1}{1 + e^{-xz}}.$$

Покажите, что она не является ядром.

Задача 3. Рассмотрим постановку оптимизационной задачи одноклассового метода опорных векторов:

$$\begin{cases} \frac{1}{2}\|w\|^2 + \sum_{i=1}^{\ell} (\xi_i - \nu\rho) \rightarrow \min_{w, \xi, \rho}, & \xi = (\xi_i)_{i=1}^{\ell}, \\ \langle w, x_i \rangle \geq \rho - \xi_i, & \xi_i \geq 0, \quad i = \overline{1, \ell}, \end{cases} \quad (0.1)$$

где $\nu \in (0, 1]$. Модель одноклассового метода опорных векторов строит решающее правило $a(x) = \text{sign}(\langle w, x \rangle - \rho)$, принимающее значение 1 на области как можно меньшего объёма, содержащей как можно больше объектов выборки. Модель $a(x)$ разделяет выборку от начала координат с максимальным отступом, такого рода модели применяются в задачах детектирования аномалий, когда требуется провести *фильтрацию* данных и отсеять выбросы или выделить наиболее нетипичные объекты относительно имеющейся выборки.

Докажите, что задача (0.1) является задачей выпуклого программирования. Для задачи (0.1) выпишите функцию Лагранжа и по ней постройте двойственную задачу, покажите, что двойственная задача является также задачей выпуклого программирования. Какие объекты в двойственной задаче являются опорными? Обобщите двойственную задачу на случай ядра $K(x_i, x_j) \stackrel{\text{def}}{=} \langle x_i, x_j \rangle$, $i, j = \overline{1, \ell}$. Покажите, что гиперпараметр ν является верхней оценкой на долю аномалий в выборке $\{x_i\}_{i=1}^{\ell}$, то есть что $\frac{1}{\ell} \sum_{i=1}^{\ell} [\langle w, x_i \rangle < \rho] \leq \nu$, где w — оптимальный вектор весов.

Задача 4. Рассмотрим следующую задачу метода опорных векторов (SVM) с двумя классами -1 и $+1$ и $p_i \in [0; 1]$, $i = \overline{1, \ell}$:

$$\frac{1}{2} \|w\|^2 + C \sum_{i=1}^{\ell} p_i (\max \{1 - y_i (\langle w, x_i \rangle + b), 0\})^2 \rightarrow \min_{w, b}, \quad C > 0. \quad (0.2)$$

Скаляры p_i обозначают важность объектов. Запишите задачу безусловной оптимизации (0.2) в виде эквивалентной задачи условной оптимизации, введя вспомогательные переменные. Выведите двойственную к этой задаче, выразив через функцию ядра $K(x_i, x_j) \stackrel{\text{def}}{=} \langle x_i, x_j \rangle$, $i, j = \overline{1, \ell}$. Выразите явно решающее правило $a(x) = \langle w, x \rangle + b$, используя ядра и важность объектов.

Задача 5. Рассмотрим нелинейное преобразование ReLU:

$$g(x) = \begin{cases} x, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

Требуется построить нейронную сеть с одним скрытым слоем из двух нейронов с активацией ReLU и одним выходным нейроном без нелинейного преобразования для классификации выборки XOR:

$$\begin{aligned} x_1 &= (0, 0), & y_1 &= 0, \\ x_2 &= (0, 1), & y_2 &= 1, \\ x_3 &= (1, 0), & y_3 &= 1, \\ x_4 &= (1, 1), & y_4 &= 0. \end{aligned}$$

Класс выдаваемый сетью определяется с помощью некоторого порога значения на выходном нейроне. Свободных членов в сети нет. Достаточно найти любое подходящее решение.

Задача 6. Критерий информативности для набора объектов R вычисляется на основе того, насколько хорошо их целевые переменные предсказываются константой (при оптимальном выборе этой константы):

$$H(R) = \min_{c \in \mathbb{Y}} \frac{1}{|R|} \sum_{(x_i, y_i) \in R} L(y_i, c),$$

где $L(y, c)$ — некоторая функция потерь. Соответственно, чтобы получить вид критерия при конкретной функции потерь, необходимо аналитически найти оптимальное значение константы и подставить его в формулу для $H(R)$.

Выведите критерии информативности для следующих функций потерь:

1. $L(y, c) = (y - c)^2$;
2. $L(y, c) = \sum_{k=1}^K (c_k - [y = k])^2$;
3. $L(y, c) = - \sum_{k=1}^K [y = k] \log c_k$.

У вас должны получиться дисперсия, критерий Джини и энтропийный критерий соответственно.

Задача 7. Пусть даны выборка X , состоящая из 8 объектов x_i , и классификатор $b(x)$, предсказывающий оценку принадлежности объекта положительному классу. Предсказания $b(x)$ и реальные метки объектов приведены ниже:

$$\begin{aligned} b(x_1) &= 0.1, & y_1 &= +1, \\ b(x_2) &= 0.8, & y_2 &= +1, \\ b(x_3) &= 0.2, & y_3 &= -1, \\ b(x_4) &= 0.9, & y_4 &= -1, \\ b(x_5) &= 0.9, & y_5 &= +1, \\ b(x_6) &= 0.3, & y_6 &= +1, \\ b(x_7) &= 0.6, & y_7 &= -1, \\ b(x_8) &= 0.95, & y_8 &= +1. \end{aligned}$$

Постройте ROC-кривую и вычислите AUC-ROC для множества классификаторов $a(x; t)$, порожденных $b(x)$, на выборке X . Множество классификаторов параметризовано с помощью t — порога, при котором в случае $b(x) > t$ для объекта x присваивается метка класса $+1$ и -1 иначе.

Задача 8. Пусть дан классификатор $b(x)$, который возвращает оценку принадлежности объекта x положительному классу. Отсортируем все объекты по убыванию ответа классификатора: $b(x_{(1)}) \geq \dots \geq b(x_{(\ell)})$. Обозначим истинные ответы на этих объектах через $y_{(1)}, \dots, y_{(\ell)}$.

Покажите, что AUC-ROC для данной выборки будет равен вероятности того, что случайно выбранный положительный объект окажется в отсортированном списке не раньше случайно выбранного отрицательного объекта.

Задача 9. Пусть дана некоторая выборка X и классификатор $b(x)$, возвращающий в качестве оценки принадлежности объекта x положительному классу 0 или 1, а не некоторое вещественное число.

1. Постройте ROC-кривую для классификатора $b(x)$ на выборке X .
2. Покажите, что AUC-ROC классификатора $b(x)$ на выборке X может быть выражен через долю правильных ответов и полноту классификатора $a(x; t)$, получающегося при выборе некоторого порога $t \in (0; 1)$. Помимо указанных величин в формулу могут входить только величины ℓ_- , ℓ_+ , ℓ (количество отрицательных, положительных и общее количество объектов в выборке X соответственно).
3. Покажите, что в случае сбалансированной выборки ($\ell_- = \ell_+$) AUC-ROC классификатора $b(x)$ на выборке X совпадает с долей правильных ответов классификатора при выборе некоторого порога $t \in (0; 1)$.

Задача 10. Пусть целевая переменная имеет отрицательное биномиальное распределение с фиксированным параметром r :

$$p(y | \mu(x)) = C_{y+r-1}^y \mu(x)^y (1 - \mu(x))^{r-y},$$

где $\mu(x) \stackrel{\text{def}}{=} \sigma(\langle w, x \rangle)$, w — веса, $\sigma(\cdot)$ — функция сигмоиды. Предложенное распределение позволяет моделировать количественные события на целых неотрицательных числах, например, сроки госпитализации пациентов.

Запишите оптимизационную задачу поиска вектора весов модели w для соответствующей обобщенной линейной модели (для метода максимального правдоподобия), выразите значение параметра $\mu(x)$ через оптимальное значение w^* и найдите матожидание ответов y , обусловленное натуральным параметром θ через дифференцирование $c(\theta)$. Совпадает ли оно с $\mu(x)$ и почему? Как будет выглядеть итоговый алгоритм прогнозирования $y = a(x)$? Напоминаем, обобщенная линейная модель выглядит следующим образом:

$$p(y | \theta, \varphi) = \exp \left(\frac{y\theta - c(\theta)}{\varphi} + h(y, \varphi) \right),$$

где θ, φ — параметры распределения, $c(\theta), h(y, \varphi)$ — параметры-функции.

Задача 11. Рассмотрим метод восстановления плотности распределения с помощью гистограмм. Разобьем все пространство на непересекающиеся области δ_i . Каждому δ_i ставится в соответствие вероятность h_i . По заданной выборке $\{x_i\}_{i=1}^\ell$, найдите оптимальные значения h_i с помощью метода максимального правдоподобия.

Задача 12. В задаче классификации имеется частично размеченная выборка. Для восстановления плотностей распределения классов вводится смесь гауссиан с явным указанием гауссианы для размеченных объектов:

$$\sum_{i=1}^{\ell} \log \pi_{y_i} p(x_i | y_i, \theta) + \sum_{i=\ell+1}^{\ell+k} \log \sum_{y \in \mathbb{Y}} \pi_y p(x_i | y, \theta) \rightarrow \max_{\theta, \pi} \quad \sum_{y \in \mathbb{Y}} \pi_y = 1,$$

где $p(x | y, \theta) = \mathcal{N}(x | \mu_y, \Sigma_y)$. Введите скрытые переменные и запишите ЕМ-алгоритм сначала в общем виде для смеси произвольных вероятностных распределений, затем для смеси гауссиан.

Задача 13. Наблюдается упорядоченная выборка (последовательность, временной ряд) бинарных значений $y = (y_1, \dots, y_n)$, $y_i \in \{0, 1\}$. Элементы выборки генерируются независимо, но известно, что в некоторый момент z меняется вероятность единиц, т.е. для всех $i < z$ $P(y_i = 1) = \theta_1$, а для всех $i \geq z$ $P(y_i = 1) = \theta_2$. Выведите ЕМ-алгоритм для восстановления смеси этих двух распределений и определения момента разладки z . Что является скрытой переменной, а что — параметрами распределений? *Задачи о разладке* (change point detection) встречаются при моделировании активности (частоты кликов) пользователей, при обнаружении предаварийных режимов работы оборудования, при выявлении заражённых участков по данным счётчика Гейгера.

Задача 14. В алгоритме K-Means минимизируется среднее внутрикластерное расстояние:

$$\sum_{k=1}^K \sum_{i=1}^{\ell} [a(x_i) = k] \|x_i - c_k\|^2.$$

Покажите, что

- при фиксированных центрах c_k каждый объект оптимально приписывать к кластеру, центр которого является ближайшим;
- при фиксированном распределении объектов по кластерам $a(x_i)$ оптимальное значения для центра вычисляется как средняя точка в кластере.