

Домашняя работа по курсу «Введение в машинное обучение»

Выполнила Жунусова Асыллия Канатовна, студент 5 курса, ВМК МГУ.

Содержание

Задача 1

Задача 2

Задача 3

Задача 4

Задача 5

Задача 6

Задача 7

Задача 8

Задача 9

Задача 10

Задача 11

Задача 12

Задача 13

Задача 14

Задача 1

Рассматриваем функцию, равную косинусу угла между двумя векторами $x, z \in \mathbb{R}^d$:

$$K(\vec{x}, \vec{z}) = \cos(\vec{x}, \vec{z}) = \frac{\langle \vec{x}, \vec{z} \rangle}{|\vec{x}| \cdot |\vec{z}|} = \left\langle \frac{\vec{x}}{|\vec{x}|}, \frac{\vec{z}}{|\vec{z}|} \right\rangle = \langle \psi(\vec{x}), \psi(\vec{z}) \rangle$$

Значит $K(\vec{x}, \vec{z})$ - ядро.

Задача 2

Рассматриваем следующую функцию на пространстве вещественных чисел:

$$K(x, z) = \frac{1}{1 + e^{-xz}}.$$

Допустим $K(x, z) = \frac{1}{1 + e^{-xz}}$ - ядро, т. е. \exists функция $\psi(x)$, такая что

$$K(x, z) = \psi(x) \cdot \psi(z).$$

Тогда $1 + e^{-xz}$ - тоже ядро, т.к. $1 + e^{-xz} = \widetilde{\psi}(x) \cdot \widetilde{\psi}(z)$, где $\widetilde{\psi}(x) = \frac{1}{\psi(x)}$.

Однако в силу свойств степени e^{-xz} невозможно представить в виде произведения функции $f(x)$ и $g(z)$.

Следовательно не существуют такие функции $\tilde{f}(x)$ и $\tilde{g}(z)$:

$$1 + e^{-xz} = \tilde{f}(x) \cdot \tilde{g}(z).$$

Это означает, что не существует функции $\widetilde{\psi}(x)$, следовательно, не существует функции $\psi(x)$. Получаем противоречие. Значит $K(x, z)$ - не ядро.

Задача 3.

$$\begin{cases} \frac{1}{2}\|w\|^2 + \sum_{i=1}^l (\xi_i - \nu p) \rightarrow \min_{w, \xi, \nu}, \xi = (\xi_i)_{i=1}^l \\ \langle w, x_i \rangle \geq p - \xi_i, \quad \xi_i \geq 0, \quad i = 1, 2, \dots, l \end{cases} \quad (3.1)$$

Очевидно, что функции $g_{1i}(w, \xi_i) = p - \xi_i - \langle w, x_i \rangle$ и $g_{2i}(\xi_i) = -\xi_i$ являются выпуклыми, так как g_{2i} - это прямая, а g_{1i} описывает плоскость.

Рассмотрим функцию $f(w, \xi, \nu) = \frac{1}{2}\|w\|^2 + \sum_{i=1}^l (\xi_i - \nu p)$.

Ее вторые производные $\frac{d^2 f}{dw^2} = \frac{1}{2} > 0$, $\frac{d^2 f}{d\xi^2} = 0$ и $\frac{d^2 f}{d\nu^2} = 0$, следовательно,

функция f тоже выпуклая. Это означает, что задача (3.1) является задачей выпуклого программирования, так как все функции выпуклые. Значит, можем использовать теоремой Каруша-Куна-Таккера.

Построим функцию Лагранжа.

$$\begin{aligned} L &= \frac{1}{2}\|w\|^2 + \sum_{i=1}^l (\xi_i - \nu p) - \sum_{i=1}^l \lambda_i (\langle w, x_i \rangle - p + \xi_i) - \sum_{i=1}^l \eta_i \xi_i = \\ &= \frac{1}{2}\|w\|^2 + \sum_{i=1}^l \xi_i (1 - \lambda_i - \eta_i) + \sum_{i=1}^l (\lambda_i p - \lambda_i \langle w, x_i \rangle - \nu p) \end{aligned}$$

Необходимые условия седовой точки функции Лагранжа:

$$\begin{aligned} \frac{dL}{dw} &= w - \sum_{i=1}^l \lambda_i x_i = 0 \Rightarrow w = \sum_{i=1}^l \lambda_i x_i; \\ \frac{dL}{dp} &= \sum_{i=1}^l \lambda_i - \nu l = 0 \Rightarrow \sum_{i=1}^l \lambda_i = \nu l; \\ \frac{dL}{d\xi_i} &= 1 - \lambda_i - \eta_i = 0 \Rightarrow \lambda_i + \eta_i = 1, \quad i = 1, 2, \dots, l; \\ \xi_i &\geq 0; \quad \eta_i \geq 0; \quad \lambda_i \geq 0 \\ \lambda_i &= 0 \text{ либо } \langle w, x_i \rangle = p - \xi_i \\ \eta_i &= 0 \text{ либо } \xi_i = 0 \end{aligned}$$

В итоге получим систему условияи ККТ

$$\begin{cases} w = \sum_{i=1}^l \lambda_i x_i; & \sum_{i=1}^l \lambda_i = \nu l; & \langle w, x_i \rangle \geq p - \xi_i \\ \xi_i \geq 0; & \eta_i \geq 0; & \lambda_i \geq 0; & \eta_i + \lambda_i = 1 \\ \lambda_i = 0 & \text{либо} & \langle w, x_i \rangle = p - \xi_i \\ \eta_i = 0 & \text{либо} & \xi_i = 0 \end{cases}$$

Построим двойственную задачу через функцию Лагранжа

$$L = \frac{1}{2} \sum_{i,j=1}^l \lambda_i \lambda_j \langle x_i, x_j \rangle - \sum_{i,j=1}^l \lambda_i \lambda_j \langle x_i, x_j \rangle - \nu p + p \sum_{i,j=1}^l \lambda_i = -\frac{1}{2} \sum_{i,j=1}^l \lambda_i \lambda_j \langle x_i, x_j \rangle$$

<p>Двойственная задача</p> $L = -\frac{1}{2} \sum_{i,j=1}^l \lambda_i \lambda_j \langle x_i, x_j \rangle \rightarrow \max_{\lambda}$ $\sum_{i=1}^l \lambda_i = \nu l; \quad 0 \leq \lambda_i \leq 1$	<p>Обобщение двойственной задачи</p> $L = -\frac{1}{2} \sum_{i,j=1}^l \lambda_i \lambda_j K(x_i, x_j) \rightarrow \max_{\lambda}$ $\sum_{i=1}^l \lambda_i = \nu l; \quad 0 \leq \lambda_i \leq 1$
--	---

Двойственная задача тоже является задачей выпуклого программирования, так как $-L$ тоже является выпуклой функцией (ее вторая производная положительна).

Типизация объектов $x_i, i = 1, 2, \dots, l$

1. $\lambda_i = 0; \eta_i = 1; \xi_i = 0; \langle w, x_i \rangle > p; a(x_i) = 1$ - периферийный.
2. $\lambda_i \in (0, 1); \eta_i \in (0, 1); \xi_i = 0; \langle w, x_i \rangle = p; a(x_i) = 0$ - опорный-граничный
3. $\lambda_i = 1; \eta_i = 0; \xi_i > 0; \langle w, x_i \rangle = p - \xi_i < p; a(x_i) = -1$ - опорный-нарушитель

Покажем, что $\frac{1}{l} \sum_{i=1}^l [\langle w, x_i \rangle < p] \leq \nu$, где w - опт. вектор весов.

$$\sum_{i=1}^l [\langle w, x_i \rangle < p] \text{ - кол-во элементов в множестве } \{p - \xi_i \leq \langle w, x_i \rangle < p\} = A.$$

Кол-во элементов в мн-ве A столько же, сколько $\lambda_i = 1$.

$$\sum_{i=1}^l [\langle w, x_i \rangle < p] = \sum_{i=1}^l [\lambda_i = 1] \leq \sum_{i=1}^l \lambda_i = 1 = \nu l.$$

$$\text{То есть } \sum_{i=1}^l [\langle w, x_i \rangle < p] \leq \nu l \iff \frac{1}{l} \sum_{i=1}^l [\langle w, x_i \rangle < p] \leq \nu.$$

Задача 4

$$\frac{1}{2}\|w\|^2 + C \sum_{i=1}^l p_i (\max\{1 - y_i(\langle w, x_i \rangle + b), 0\})^2 \rightarrow \min_{w,b}, \quad C > 0 \quad (4.1)$$

Перепишем задачу безусловной оптимизации (4.1) в виде эквивалентной задачи условной оптимизации

$$\begin{cases} \frac{1}{2}\|w\|^2 + C \sum_{i=1}^l p_i \xi_i^2 \rightarrow \min_{w,b,\xi} \\ \xi_i \geq 1 - y_i(\langle w, x_i \rangle + b); \\ \xi_i \geq 0, \quad i = 1, 2, \dots, l \end{cases}$$

Построим функцию Лагранжа.

$$L = \frac{1}{2}\|w\|^2 + \sum_{i=1}^l \xi_i (C p_i \xi_i - \lambda_i - \eta_i) + \sum_{i=1}^l \lambda_i (1 - y_i(\langle w, x_i \rangle + b))$$

Необходимые условия седовой точки функции Лагранжа:

$$0 = \frac{dL}{dw} = w - \sum_{i=1}^l \lambda_i y_i x_i \implies w = \sum_{i=1}^l \lambda_i y_i x_i$$

$$0 = \frac{dL}{db} = \sum_{i=1}^l \lambda_i y_i \implies \sum_{i=1}^l \lambda_i y_i = 0$$

$$0 = \frac{dL}{d\xi_i} = 2\xi_i C p_i - \lambda_i - \eta_i \implies \lambda_i + \eta_i = 2\xi_i C p_i$$

$$\lambda_i \geq 0; \quad \eta_i \geq 0$$

Построим двойственную задачу через функцию Лагранжа

$$L = \frac{1}{2} \sum_{i,j=1}^l \lambda_i \lambda_j y_i y_j \langle x_i, x_j \rangle - \sum_{i=1}^l \xi_i C p_i + \sum_{i=1}^l \lambda_i - \sum_{i,j=1}^l \lambda_i \lambda_j y_i y_j \langle x_i, x_j \rangle$$

Двойственная задача

$$\begin{cases} L = -\frac{1}{2} \sum_{i,j=1}^l \lambda_i \lambda_j y_i y_j K(x_i, x_j) - C \sum_{i=1}^l \xi_i p_i + \sum_{i=1}^l \lambda_i \rightarrow \max_{\lambda,\xi} \\ \sum_{i=1}^l \lambda_i y_i = 0; \quad 0 \leq \lambda_i \leq 2C p_i \xi_i, \quad i = 1, 2, \dots, l \end{cases}$$

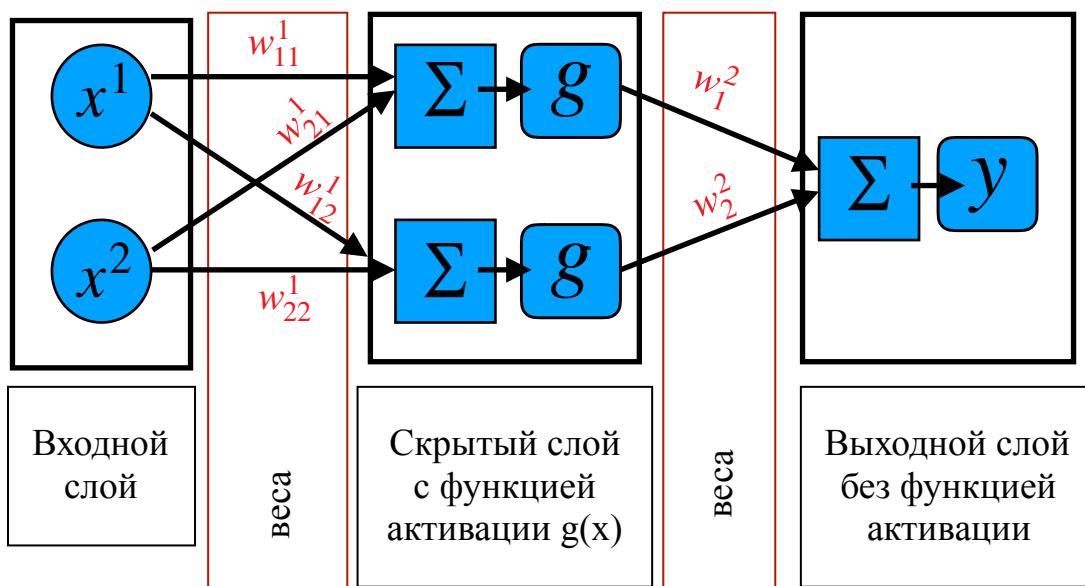
Решение прямой задачи

$$\begin{cases} w = \sum_{i=1}^l \lambda_i y_i x_i \\ b = y_i - \langle w, x_i \rangle, \text{ для } \forall i : \lambda_i \in (0, 2Cp_i \xi_i) \end{cases}$$

$$a(x) = \sum_{i=1}^l \lambda_i y_i K(x_i, x) + b$$

Задача 5

Схематичное представление нейронной сети, на вход подается вектор $x = [x^1, x^2]$, потом на входной вектор умножают справа на матрицу весов $w^1 = \begin{pmatrix} w_{11}^1 & w_{12}^1 \\ w_{21}^1 & w_{22}^1 \end{pmatrix}$, результаты которого проходят через функцию активации $g(x)$, потом умножают на матрицу весов $w^2 = \begin{pmatrix} w_1^2 \\ w_2^2 \end{pmatrix}$, на выходе мы получаем скаляр y .



Определим вектор весов $w^1 = \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix}$ и $w^2 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$.

Проверим, что вернет нейронная сеть при x_1, x_2, x_3, x_4 .

$$y_1 = g(x_1 w^1) w^2 = g([0 \ 0] w^1) w^2 = g([0 \ 0]) w^2 = [0 \ 0] w^2 = 0$$

$$\begin{aligned}
y_2 &= g(x_2 w^1) w^2 = g([0 \ 1] w^1) w^2 = g([-1 \ 1]) w^2 = [0 \ 1] w^2 = 1 \\
y_3 &= g(x_3 w^1) w^2 = g([1 \ 0] w^1) w^2 = g([1 \ -1]) w^2 = [1 \ 0] w^2 = 1 \\
y_4 &= g(x_4 w^1) w^2 = g([1 \ 1] w^1) w^2 = g([0 \ 0]) w^2 = [0 \ 0] w^2 = 0
\end{aligned}$$

Задача 6

Критерий информативности $H(R) = \min_{c \in \mathbb{Y}} \frac{1}{|R|} \sum_{(x_i, y_i) \in R} L(y_i, c)$.

1. $L(y, c) = (y - c)^2$

$$f(c) = \frac{1}{|R|} \sum_{(x_i, y_i) \in R} (y_i - c)^2$$

$$\frac{df(c)}{dc} = -\frac{2}{|R|} \sum_{(x_i, y_i) \in R} (y_i - c) = 0 \implies c = \frac{1}{|R|} \sum_{(x_i, y_i) \in R} y_i = \bar{y}$$

$$\frac{d^2 f(c)}{dc^2} = 2 > 0 \implies c = \bar{y} \text{ - точка минимума}$$

$$H(R) = \frac{1}{|R|} \sum_{(x_i, y_i) \in R} (y_i - \bar{y})^2$$

2. $L(y, c) = \sum_{k=1}^K (c_k - [y = k])^2$. Причем $\sum_{k=1}^K c_k = 1$.

Введем обозначения $p_k = \frac{1}{|R|} \sum_{(x_i, y_i) \in R} [y_i = k]$.

$$\begin{aligned}
H(R) &= \min_{c \in \mathbb{Y}} \frac{1}{|R|} \sum_{(x_i, y_i) \in R} \sum_{k=1}^K (c_k - [y = k])^2 = \\
&= \min_{c \in \mathbb{Y}} \sum_{k=1}^K \left(c_k^2 - 2c_k \frac{1}{|R|} \sum_{(x_i, y_i) \in R} [y = k] + \frac{1}{|R|} \sum_{(x_i, y_i) \in R} [y = k] \right) = \\
&= \min_{c \in \mathbb{Y}} \sum_{k=1}^K (c_k^2 + p_k(1 - 2c_k))
\end{aligned}$$

$$f_k(c_k) = c_k^2 + p_k(1 - 2c_k)$$

$$\frac{df_k(c_k)}{dc_k} = 2c_k - 2p_k = 0 \implies c_k = p_k;$$

$$\frac{d^2f_k(c_k)}{dc_k^2} = 2 > 0 \implies c_k = p_k - \text{точка минимума}$$

$$H(R) = \sum_{k=1}^K (p_k^2 + p_k - 2p_k^2) = \sum_{k=1}^K p_k(1 - p_k)$$

$$3. L(y, c) = - \sum_{k=1}^K [y = k] \log c_k$$

$$\begin{cases} H(R) = - \frac{1}{|R|} \sum_{(x_i, y_i) \in R} \sum_{k=1}^K [y = k] \log c_k = - \sum_{k=1}^K p_k \log c_k \rightarrow \min\{c\} \\ \sum_{k=1}^K c_k = 1 \end{cases}$$

Построим функцию Лагранжа

$$L = - \sum_{k=1}^K p_k \log c_k + \lambda \left(\sum_{k=1}^K c_k - 1 \right)$$

$$\frac{dL}{dc_k} = - \frac{p_k}{c_k} + \lambda = 0 \implies c_k = \frac{p_k}{\lambda} - \text{точка минимума}$$

$$1 = \sum_{k=1}^K c_k = \sum_{k=1}^K \frac{p_k}{\lambda} = \frac{1}{\lambda} \sum_{k=1}^K p_k = \frac{1}{\lambda} \implies \lambda = 1$$

$$H(R) = - \sum_{k=1}^K p_k \log p_k$$


Задача 7

$$b(x_1) \leq b(x_3) \leq b(x_6) \leq b(x_7) \leq b(x_2) \leq b(x_4) \leq b(x_5) \leq b(x_8)$$

0.1	0.2	0.3	0.6	0.8	0.9	0.9	0.95
+1	-1	+1	-1	+1	-1	+1	+1

$$a(x) = \text{sign}(b(x) - t)$$

t=0.95 FPR=0 TPR=0	t=0.9 FPR=0 TPR=1/5=0.2	t=0.8 FPR=1/3=0.3(3) TPR=2/5=0.4	t=0.6 FPR=1/3=0.3(3) TPR=3/5=0.6
t=0.3 FPR=2/3=0.6(6) TPR=3/5=0.6	t=0.2 FPR=2/3=0.6(6) TPR=4/5=0.8	t=0.1 FPR=1 TPR=4/5=0.8	t=0 FPR=1 TPR=1



Рос-кривая

$$AUC - ROC = \frac{1}{3} \cdot \frac{0.2 + 0.4}{2} + \frac{1}{3} \cdot 0.6 + \frac{1}{3} \cdot 0.8 = \frac{17}{30} \approx 0.56667$$

Задача 8

Разберем процедуру построение AUC-ROC при

$$b(x_{(1)}) < b(x_{(2)}) < \dots < b(x_{(n)})$$

Сначала все объекты сортируются по оценке классификатора. Стартуем из точки $(0,0)$ - она соответствует порогу $y_{(l)}$. Начинаем идти от большей оценки к меньшей.

Если текущий объект имеет класс «1», то у алгоритма увеличивается TPR; значит, ROC-кривая сдвигается вверх на $\frac{1}{l_+}$ (l_+ -число объектов в положительного класса).

Если у текущего объекта класс «-1», то у алгоритма увеличивается FPR; значит, ROC-кривая сдвигается вправо на $\frac{1}{l_-}$ (l_- -число объектов

отрицательного класса), а к AUC надо прибавить $\sum_{j=i+1}^l [y_{(j)} = +1] \cdot \frac{1}{l_+ l_-}$.

$$\text{Получаем } AUC = \frac{1}{l_+ l_-} \sum_{i=1}^l [y_{(i)} = -1] \sum_{j=i+1}^l [y_{(j)} = +1] = \frac{1}{l_+ l_-} \sum_{i < j} [y_{(i)} < y_{(j)}].$$

Однако в случае $\exists k < l : b(x_{(k)}) = b(x_{(k+1)})$ и $y_{(k)} < y_{(k+1)}$, такое утверждение является не верным.

Приведу контр-пример.

$$b(x_1) = 0.5 \quad y_1 = -1$$

$$b(x_2) = 0.5 \quad y_2 = +1$$

$$\frac{1}{2} = AUC < \frac{1}{l_+ l_-} \sum_{i < j} [y_{(i)} < y_{(j)}] = 1$$

Задача 9


1. Т. к. классификатор $b(x)$ возвращает только 2 значения, то, отсортировав его, получим:

$$0 = b(x_{(1)}) = b(x_{(2)}) = \dots = b(x_{(l_-)}) < b(x_{(l_-+1)}) = b(x_{(l_-+2)}) = \dots = b(x_{(l)}) = 1$$

с истинными ответами $y_{(1)}, y_{(2)}, \dots, y_{(l)}$ соответственно.

В этом случае у ROC-кривой будут 3 точки:

$t=1$ $FPR=0$ $TPR=0$	$t=0$ $FPR=\frac{1}{l_-} \sum_{i=1}^{l_+} [y_{(l_-+i)} = -1]$ $TPR=\frac{1}{l_+} \sum_{i=1}^{l_+} [y_{(l_-+i)} = +1]$	$t<0$ $FPR=1$ $TPR=1$
-----------------------------	---	-----------------------------



$$\begin{aligned}
 2. \quad AUC &= \frac{TPR \cdot FPR}{2} + \frac{(1 + TPR) \cdot (1 - FPR)}{2} = \\
 &= \frac{1 - FPR + TPR}{2} = \frac{TNR + TPR}{2}
 \end{aligned}$$

$$TNR = \frac{1}{l_-} \sum_{i=1}^{l_-} [y_{(i)} = -1]$$

$$AUC = \frac{1}{2l_-} \sum_{i=1}^{l_-} [y_{(i)} = -1] + \frac{1}{2l_+} \sum_{i=1}^{l_+} [y_{(l_-+i)} = +1]$$

3. Если $l_- = l_+$, то

$$AUC = \frac{1}{2l_+} \left(\sum_{i=1}^{l_-} [y_{(i)} = -1] + \sum_{i=1}^{l_+} [y_{(l_-+i)} = +1] \right) = \frac{TP + TN}{2} = accuracy.$$

Задача 10

Сначала посчитаем мат. ожидание и дисперсию для отрицательного биномиального распределения.

$$P(y = k) = C_{k+r-1}^k p^r q^k.$$

Обозначим мат ожидание A и вычислим ее

$$\begin{aligned} A = Ey &= \sum_{k=0}^{+\infty} k \cdot C_{k+r-1}^k p^r q^k = \sum_{k=1}^{+\infty} k \cdot \frac{(k+r-1)!}{k!(r-1)!} p^r q^k = \\ &= q \sum_{k=0}^{+\infty} k \cdot \frac{(k+r-1)!(k+r)}{k!(r-1)!} p^r q^k = q \sum_{k=0}^{+\infty} k \cdot C_{k+r-1}^k p^r q^k + \\ &+ qr \sum_{k=0}^{+\infty} C_{k+r-1}^k p^r q^k = Aq + qr \\ A &= \frac{rq}{1-q} = \frac{rq}{p}; \quad \text{то есть } Ey = \frac{rq}{p}. \end{aligned}$$

Обозначим второй начальный момент B и вычислим ее

$$\begin{aligned} B = Ey^2 &= \sum_{k=0}^{+\infty} k^2 \cdot C_{k+r-1}^k p^r q^k = \sum_{k=0}^{+\infty} (k^2 - k + k) \cdot C_{k+r-1}^k p^r q^k = \\ &= \sum_{k=2}^{+\infty} k(k-1) \cdot \frac{(k+r-1)!}{k!(r-1)!} p^r q^k + \sum_{k=1}^{+\infty} k \cdot \frac{(k+r-1)!}{k!(r-1)!} p^r q^k = \\ &= q^2 \sum_{k=0}^{+\infty} (k+r+1)(k+r) \cdot \frac{(k+r-1)!}{k!(r-1)!} p^r q^k + A = \\ &= q^2 \sum_{k=0}^{+\infty} k^2 \cdot C_{k+r-1}^k p^r q^k + q^2(2r+1) \sum_{k=0}^{+\infty} k \cdot C_{k+r-1}^k p^r q^k + \\ &+ q^2(r+r^2) \sum_{k=0}^{+\infty} C_{k+r-1}^k p^r q^k + \frac{rq}{p} = \\ &= q^2 B + \frac{q^3(2r+1)r}{p} + q^2(r+1)r + \frac{rq}{p} \\ B(1-q^2) &= \frac{1}{p} rq(q+1)(qr+1) \end{aligned}$$

$$B = \frac{r^2 q^2}{p^2} + \frac{r q}{p^2}$$

Дисперсия по формуле вычисляется

$$Dy = Ey^2 - (Ey)^2 = B - A^2 = \frac{r q}{p^2}$$

Построим обобщенную линейную модель:

$$p(y|\theta_i, \phi_i) = \exp\left(\frac{y_i \theta_i - c(\theta_i)}{\phi_i} + h(y_i, \phi_i)\right)$$

Известны следующие свойства :

- 1) $Ey_i = c'(\theta_i)$;
- 2) $Dy_i = \phi_i c''(\theta_i)$;

$$P(y_i|\mu(x_i)) = C_{y_i+r-1}^{y_i} \mu(x_i)^r (1 - \mu(x_i))^{y_i} = \exp(y_i \ln(1 - \mu(x_i)) + r \ln \mu(x_i) + \ln C_{y_i+r-1}^{y_i})$$

$$\theta_i = \ln(1 - \mu(x_i)) \implies \mu(x_i) = 1 - e^{\theta_i}$$

$$Ey_i = \frac{r(1 - \mu(x_i))}{\mu(x_i)} = \frac{r}{e^{-\theta_i} - 1} = c'(\theta_i) \implies c(\theta_i) = -r \ln(e^{\theta_i} - 1)$$

$$Dy_i = \frac{r(1 - \mu(x_i))}{\mu^2(x_i)} = \frac{r e^{\theta_i}}{(1 - e^{\theta_i})^2} = c''(\theta_i) \cdot \phi_i$$

$$c''(\theta_i) = -\frac{r e^{\theta_i}}{(e^{\theta_i} - 1)^2} \implies \phi_i = \frac{Dy_i}{c''(\theta_i)} = -1$$

То есть

$$\begin{aligned} P(y_i|\mu(x_i)) &= \exp(y_i \ln(1 - \mu(x_i)) + r \ln \mu(x_i) + \ln C_{y_i+r-1}^{y_i}) = \\ &= \exp(y_i \theta_i - c(\theta_i) + h(y_i, \phi_i)) = p(y_i|\theta_i, \phi_i) \end{aligned}$$

Метод максимального правдоподобия

$$L(w) = \prod_{i=1}^l p(y_i|\theta_i, \phi_i) \rightarrow \max_w$$

но удобнее прологарифмировать и решать следующую оптимизационную задачу

$$\ln L(w) = \sum_{i=1}^l (y_i \theta_i - c(\theta_i) + h(y_i, \phi_i)) \rightarrow \max_w,$$

где $\theta_i = \ln(1 - \sigma(\langle w, x_i \rangle))$,

$$c(\theta_i) = -r \ln(e^{\theta_i} - 1),$$

$$\phi_i = 1, h(y_i, \phi_i) = \ln C_{y_i+r-1}^{y_i}.$$

Итоговый алгоритм прогнозирования $y(x) = \frac{r(1 - \sigma(\langle w, x \rangle))}{\sigma(\langle w, x \rangle)}$

Задача 11

Вероятность события $x \in \sigma_i$ равно h_i ,

а вероятность события $x \notin \sigma_i$ равно $1 - h_i$.

Запишем плотность распределения того, что случайная величина x попадет в область σ_i .

$$f(x) = h_i^{[x \in \sigma_i]} \cdot (1 - h_i)^{[x \notin \sigma_i]}.$$

$$L = \prod_{j=1}^l f(x_j) = h_i^{\sum_{j=1}^l [x_j \in \sigma_i]} \cdot (1 - h_i)^{\sum_{j=1}^l (1 - [x_j \in \sigma_i])}$$

$$l = \ln L = \sum_{j=1}^l [x_j \in \sigma_i] \ln h_i + \sum_{j=1}^l (1 - [x_j \in \sigma_i]) \ln(1 - h_i)$$

$$\frac{dl}{dh_i} = \sum_{j=1}^l \left(\frac{[x_j \in \sigma_i]}{h_i} - \frac{1 - [x_j \in \sigma_i]}{1 - h_i} \right) = 0$$

$$\sum_{j=1}^l ([x_j \in \sigma_i] - h_i) = \sum_{j=1}^l [x_j \in \sigma_i] - lh_i = 0$$

$$h_i = \frac{1}{l} \sum_{j=1}^l [x_j \in \sigma_i] - \text{оптимальное значение } h_i \text{ полученное с помощью}$$

метода максимального правдоподобия.

Задача 12

Пусть $m = |\mathbb{Y}|$ и $y_i \in \{1, \dots, m\}$.

Тогда

$$\begin{aligned} \sum_{i=1}^l \log \pi_{y_i} p(x_i | y_i) + \sum_{i=l+1}^{l+k} \log \sum_{j=1}^m \pi_j p(x_i | j) &\rightarrow \max_{\pi, \theta} \\ \sum_{y \in \mathbb{Y}} \pi_y &= \sum_{j=1}^m \pi_j = 1 \end{aligned} \quad (12.1)$$

Причем $\pi_j = p(j) \in (0, 1)$ и $p(x_i) = \sum_{j=1}^m p(x_i | j) p(j) = \sum_{j=1}^m \pi_j p(x_i | j)$.

1) Е-шаг

Построим матрицу g_{ij} :

$$\begin{aligned} \text{при } 1 \leq i \leq l \quad g_{ij} &= p(j | x_i) = [y_i = j] \\ \text{при } l+1 \leq i \leq l+k \quad g_{ij} &= p(j | x_i) = \frac{p(j)p(x_i | j)}{p(x_i)} = \frac{\pi_j p(x_i | j)}{p(x_i)} \end{aligned}$$

2) М - шаг

Запишем Лагранжиан

$$L(\pi, \theta) = \sum_{i=1}^l \log \pi_{y_i} p(x_i | y_i) + \sum_{i=l+1}^{l+k} \log \sum_{j=1}^m \pi_j p(x_i | j) - \lambda \left(\sum_{j=1}^m \pi_j - 1 \right) \rightarrow \max_{\pi, \theta}$$

Необходимые условия седовой точки функции Лагранжа:

$$\text{a) } \frac{dL}{d\pi_a} = 0 \quad \text{b) } \frac{dL}{d\theta_a} = 0$$

Рассмотрим пункт а

$$\begin{aligned} \frac{dL}{d\pi_a} &= \sum_{i=1}^l \frac{p(x_i | y_i) [y_i = a]}{\pi_{y_i} p(x_i | y_i)} + \sum_{i=l+1}^{l+k} \frac{p(x_i | a)}{p(x_i)} - \lambda = \\ &= \frac{1}{\pi_a} \sum_{i=1}^l [y_i = a] + \frac{1}{\pi_a} \sum_{i=l+1}^{l+k} g_{ia} - \lambda = \frac{1}{\pi_a} \sum_{i=1}^{l+k} g_{ia} - \lambda = 0 \end{aligned}$$

В итоге получим, что $\pi_a = \frac{1}{\lambda} \sum_{i=1}^{l+k} g_{ia}$.

Подставим полученное π_a в (12.1) :

$$1 = \sum_{a=1}^m \pi_a = \sum_{a=1}^m \left(\frac{1}{\lambda} \sum_{i=1}^{l+k} g_{ia} \right) = \frac{1}{\lambda} \sum_{i=1}^{l+k} \sum_{a=1}^m g_{ia} = \frac{1}{\lambda} \sum_{i=1}^{l+k} 1 = \frac{l+k}{\lambda}$$

то есть $\lambda = l+k$

В итоге получаем $\pi_a = \frac{1}{l+k} \sum_{i=1}^{l+k} g_{ia}$

Рассмотрим пункт b

$$\begin{aligned} \frac{dL}{d\theta_a} &= \sum_{i=1}^l \frac{[y_i = a] \pi_{y_i} \frac{d}{d\theta_a} p(x_i | a)}{\pi_{y_i} p(x_i | y_i)} + \sum_{i=l+1}^{l+k} \frac{\pi_a \frac{d}{d\theta_a} p(x_i | a)}{p(x_i)} = \\ &= \sum_{i=1}^l [y_i = a] \frac{d}{d\theta_a} \ln p(x_i | a) + \sum_{i=l+1}^{l+k} \frac{\pi_a p(x_i | a)}{p(x_i)} \frac{d}{d\theta_a} \ln p(x_i | a) = \\ &= \sum_{i=1}^{l+k} g_{ia} \frac{d}{d\theta_a} \ln p(x_i | a) = \frac{d}{d\theta_a} \left(\sum_{i=1}^{l+k} g_{ia} \ln p(x_i | a) \right) = 0 \end{aligned}$$

Значит $\theta_a = \arg \max_{\theta} \sum_{i=1}^{l+k} g_{ia} \ln p(x_i | a)$, где $a \in \{1, \dots, m\}$.

В итоге получаем ЕМ-алгоритм в общем виде:

Е-шаг:

$$g_{ij} = \begin{cases} [y_i = j] & \text{при } 1 \leq i \leq l \\ \frac{\pi_j p(x_i | j)}{p(x_i)} & \text{при } l+1 \leq i \leq l+k \end{cases} \quad (12.2)$$

М-шаг:

$$\pi_a = \frac{1}{l+k} \sum_{i=1}^{l+k} g_{ia}, \text{ где } a \in \{1, \dots, m\}. \quad (12.3)$$

$$\theta_a = \arg \max_{\theta} \sum_{i=1}^{l+k} g_{ia} \ln p(x_i | a), \text{ где } a \in \{1, \dots, m\} \quad (12.4)$$

Теперь запишем для смеси гауссиан

Плотность гауссовского распределение при параметрах (μ_y, Σ_y) .

$$p(x_i | j) = \frac{\exp(-\frac{1}{2}(x_i - \mu_j)^T \Sigma_j^{-1}(x_i - \mu_j))}{\sqrt{(2\pi)^n \det \Sigma_j}}$$

Подставим эту плотность в (12.2) и получим E-шаг:

$$g_{ij} = \begin{cases} [y_i = j] & \text{при } 1 \leq i \leq l \\ \frac{\pi_j \exp(-\frac{1}{2}(x_i - \mu_j)^T \Sigma_j^{-1}(x_i - \mu_j))}{\sqrt{(2\pi)^n \det \Sigma_j}} & \text{при } l+1 \leq i \leq l+k \\ \sum_{s=1}^m \frac{\pi_s \exp(-\frac{1}{2}(x_i - \mu_s)^T \Sigma_s^{-1}(x_i - \mu_s))}{\sqrt{(2\pi)^n \det \Sigma_s}} & \end{cases}$$

Формула (12.3) остается без изменений, поэтому будем просчитывать

$$\text{a) } \frac{dL}{d\mu_j} = 0 \quad \text{и} \quad \text{b) } \frac{dL}{d\Sigma_j} = 0.$$

Рассмотрим пункт а

$$\ln p(x_i | j) = -\frac{1}{2}(x_i - \mu_j)^T \Sigma_j^{-1}(x_i - \mu_j) - \frac{1}{2} \ln(2\pi)^n - \frac{1}{2} \ln \det \Sigma_j$$

$$\frac{d}{d\mu_j} \ln p(x_i | j) = \Sigma_j^{-1}(x_i - \mu_j)$$

$$\frac{dL}{d\mu_j} = \sum_{i=1}^{l+k} g_{ij} \frac{d}{d\mu_j} \ln p(x_i | j) = \sum_{i=1}^{l+k} g_{ij} \Sigma_j^{-1}(x_i - \mu_j) = \Sigma_j^{-1} \sum_{i=1}^{l+k} g_{ij}(x_i - \mu_j) = 0$$

$$\text{В итоге находим параметр } \mu_j = \frac{\sum_{i=1}^{l+k} g_{ij} x_i}{\sum_{i=1}^{l+k} g_{ij}}.$$

Рассмотрим пункт b

Введем обозначения $\Lambda = \Sigma^{-1}$ и вместо $\frac{dL}{d\Sigma}$ будем считать $\frac{dL}{d\Lambda}$.

Тогда перепишем прологарифмированную плотность

$$\ln p(x_i | j) = -\frac{1}{2}(x_i - \mu_j)^T \Lambda_j (x_i - \mu_j) + \frac{1}{2} \ln \det \Lambda_j - \frac{n}{2} \ln 2\pi$$

Причем сделаем следующее преобразования

$$(x_i - \mu_j)^T \Lambda_j (x_i - \mu_j) = \text{trace}(\Lambda_j (x_i - \mu_j)(x_i - \mu_j)^T)$$

Тогда

$$\frac{d}{d\Lambda_j} \ln p(x_i | j) = -\frac{1}{2} \frac{d}{d\Lambda_j} \text{trace}(\Lambda_j (x_i - \mu_j)(x_i - \mu_j)^T) + \frac{1}{2 \det \Lambda_j} \frac{d}{d\Lambda_j} \det \Lambda_j$$

Учитывая, что $\frac{d}{dA} \text{trace}(AB) = B^T$ и $\frac{d}{dA} \det A = A^{-1} \det A$, получаем

$$\frac{d}{d\Lambda_j} \ln p(x_i | j) = -\frac{1}{2} (x_i - \mu_j)(x_i - \mu_j)^T + \frac{1}{2} \Lambda_j^{-1}$$

$$\frac{dL}{d\Lambda_j} = \sum_{i=1}^{l+k} g_{ij} \frac{d}{d\Lambda_j} \ln p(x_i | j) = -\frac{1}{2} \sum_{i=1}^{l+k} g_{ij} \left((x_i - \mu_j)(x_i - \mu_j)^T - \Lambda_j^{-1} \right) = 0$$

$$\Lambda_j^{-1} = \frac{\sum_{i=1}^{l+k} g_{ij} (x_i - \mu_j)(x_i - \mu_j)^T}{\sum_{i=1}^{l+k} g_{ij}}$$

Таким образом нашли $\Sigma_j = \frac{\sum_{i=1}^{l+k} g_{ij} (x_i - \mu_j)(x_i - \mu_j)^T}{\sum_{i=1}^{l+k} g_{ij}}$

В итоге получаем ЕМ-алгоритм для смеси гауссиан :

Е-шаг:

$$g_{ij} = \begin{cases} [y_i = j] & \text{при } 1 \leq i \leq l \\ \frac{\pi_j \exp(-\frac{1}{2}(x_i - \mu_j)^T \Sigma_j^{-1} (x_i - \mu_j))}{\sqrt{(2\pi)^n \det \Sigma_j}} & \text{при } l+1 \leq i \leq l+k \\ \frac{\sum_{s=1}^m \pi_s \exp(-\frac{1}{2}(x_i - \mu_s)^T \Sigma_s^{-1} (x_i - \mu_s))}{\sqrt{(2\pi)^n \det \Sigma_s}} & \end{cases}$$

М- шаг:

$$\pi_j = \frac{1}{l+k} \sum_{i=1}^{l+k} g_{ij} \quad \mu_j = \frac{\sum_{i=1}^{l+k} g_{ij} x_i}{\sum_{i=1}^{l+k} g_{ij}}$$

$$\Sigma_j = \frac{\sum_{i=1}^{l+k} g_{ij} (x_i - \mu_j)(x_i - \mu_j)^T}{\sum_{i=1}^{l+k} g_{ij}}$$

Задача 13

Рассмотрим выборку, имеющее следующее распределение

$$P(y_i) = P(i < z)P(y_i | i < z) + P(i \geq z)P(y_i | i \geq z)$$

Причем известно, что для всех $i < z$

$$P(y_i | i < z) = [y_i = 1]\theta_1 + [y_i = 0](1 - \theta_1),$$

а для всех $i \geq z$

$$P(y_i | i \geq z) = [y_i = 1]\theta_2 + [y_i = 0](1 - \theta_2)$$

Обозначим

$$w_i := P(i < z),$$

$$P_1(y_i) := P(y_i | i < z),$$

$$P_2(y_i) := P(y_i | i \geq z)$$

Е-шаг:

$$g_{i1} = P(i < z | y_i) = \frac{P(i < z)P(y_i | i < z)}{P(y_i)} = \frac{w_i P_1(y_i)}{P(y_i)}$$

$$g_{i2} = P(i \geq z | y_i) = \frac{P(i \geq z)P(y_i | i \geq z)}{P(y_i)} = \frac{(1 - w_i)P_2(y_i)}{P(y_i)}$$

М-шаг:

Запишем задачу выпуклого программирования

$$\begin{cases} -\sum_{i=1}^n \ln p(y_i) \rightarrow \min_{w, \theta} \\ 1 = w_1 > w_2 > \dots > w_n = 0 \end{cases}$$

Запишем Лагранжиан

$$L(w, \theta) = -\sum_{i=1}^n \ln p(y_i) + \sum_{i=1}^{n-1} \lambda_i (w_{i+1} - w_i);$$

Необходимые условия седовой точки функции Лагранжа:

$$1) \frac{dL}{dw_i} = -\frac{d}{dw_i} \ln p(y_i) - \lambda_i + \lambda_{i-1} = 0 \quad \text{при } i = 2, \dots, n-1$$

$$2) \frac{dL}{d\theta_1} = - \sum_{i=1}^n \frac{d}{d\theta_1} \ln p(y_i) \quad \text{и} \quad 3) \frac{dL}{d\theta_2} = - \sum_{i=1}^n \frac{d}{d\theta_2} \ln p(y_i)$$

1) Ищем вектор весов w

$$\frac{d}{dw_i} \ln p(y_i) = \frac{p_1(y_i) - p_2(y_i)}{p(y_i)} = \frac{g_{i1}}{w_i} - \frac{g_{i2}}{1 - w_i}$$

Из-за условий дополняющей нежесткости, следует, что все $\lambda_i = 0$, так как $w_i \neq w_{i+1}$ при $i = 1, \dots, n - 1$.

Значит

$$0 = \frac{dL}{dw_i} = - \frac{d}{dw_i} \ln p(y_i) = - \frac{g_{i1}}{w_i} + \frac{g_{i2}}{1 - w_i} \implies w_i = g_{i1} \text{ при } 1 < i < n$$

2) Ищем параметр θ_1

$$\begin{aligned} \frac{d}{d\theta_1} \ln p(y_i) &= \frac{w_i \frac{d}{d\theta_1} p_1(y_i)}{p(y_i)} = \frac{w_i ([y_i = 1] - [y_i = 0])}{p(y_i)} = \\ &= \frac{w_i ([y_i = 1] - [y_i = 0])}{p_1(y_i)} \cdot \frac{p_1(y_i)}{p(y_i)} = \frac{[y_i = 1] - [y_i = 0]}{p_1(y_i)} \cdot g_{i1} = \\ &= g_{i1} \cdot \frac{[y_i = 1] - [y_i = 0]}{([y_i = 1] - [y_i = 0])\theta_1 + [y_i = 0]} = \\ &= g_{i1} \cdot \frac{1}{\theta_1 + \frac{[y_i = 0]}{[y_i = 1] - [y_i = 0]}} = g_{i1} \cdot \frac{1}{\theta_1 - [y_i = 0]} = \\ &= g_{i1} \cdot \left(\frac{1}{\theta_1} \cdot [y_i = 1] - \frac{1}{1 - \theta_1} \cdot [y_i = 0] \right) \end{aligned}$$

$$\begin{aligned} \sum_{i=1}^n \frac{d}{d\theta_1} \ln p(y_i) &= \sum_{i=1}^n g_{i1} \cdot \frac{1}{\theta_1 - [y_i = 0]} = \\ &= \frac{1}{\theta_1} \sum_{i=1}^n g_{i1} [y_i = 1] - \frac{1}{1 - \theta_1} \sum_{i=1}^n g_{i1} [y_i = 0] = \\ &= \frac{1}{\theta_1} \sum_{i=1}^n g_{i1} [y_i = 1] - \frac{1}{1 - \theta_1} \sum_{i=1}^n g_{i1} (1 - [y_i = 1]) = \end{aligned}$$

$$= \frac{1}{\theta_1(1-\theta_1)} \sum_{i=1}^n g_{i1}[y_i = 1] - \frac{1}{1-\theta_1} \sum_{i=1}^n g_{i1}$$

$$\begin{aligned} 0 &= \frac{dL}{d\theta_1} = - \sum_{i=1}^n \frac{d}{d\theta_1} \ln p(y_i) = \\ &= - \frac{1}{\theta_1(1-\theta_1)} \sum_{i=1}^n g_{i1}[y_i = 1] + \frac{1}{1-\theta_1} \sum_{i=1}^n g_{i1} \end{aligned}$$

$$\theta_1 = \frac{\sum_{i=1}^n g_{i1}[y_i = 1]}{\sum_{i=1}^n g_{i1}}$$

3) Аналогично ищем параметр θ_2

$$\theta_2 = \frac{\sum_{i=1}^n g_{i2}[y_i = 1]}{\sum_{i=1}^n g_{i2}}$$

Ответ:

Е-шаг :

$$\begin{aligned} g_{i1} &= P(i < z | y_i) = \frac{P(i < z)P(y_i | i < z)}{P(y_i)} = \frac{w_i P_1(y_i)}{P(y_i)} \\ g_{i2} &= P(i \geq z | y_i) = \frac{P(i \geq z)P(y_i | i \geq z)}{P(y_i)} = \frac{(1 - w_i)P_2(y_i)}{P(y_i)} \end{aligned}$$

М-шаг:

$$w_i = g_{i1} \text{ при } 1 < i < n ; \quad w_1 = 1 ; w_n = 0;$$

$$\theta_1 = \frac{\sum_{i=1}^n g_{i1}[y_i = 1]}{\sum_{i=1}^n g_{i1}};$$

$$\theta_2 = \frac{\sum_{i=1}^n g_{i2}[y_i = 1]}{\sum_{i=1}^n g_{i2}}$$

Задача 14

$$\sum_{k=1}^K \sum_{i=1}^l [a(x_i) = k] \|x_i - c_k\|^2 \rightarrow \min_{c_k, w}$$

1) зафиксируем c_k , нужно минимизировать по w .

$$\forall i \sum_{k=1}^K [a(x_i) = k] \|x_i - c_k\|^2 \rightarrow \min_w \implies a(x_i) = \arg \min_{k=1, \dots, K} \|x_i - c_k\|^2$$

2) зафиксируем w , нужно минимизировать по c_k .

$$\forall k f(c_k) = \sum_{i=1}^l [a(x_i) = k] \|x_i - c_k\|^2 \rightarrow \min_{c_k}$$

$$\frac{df(c_k)}{dc_k} = \frac{d}{dc_k} \sum_{i=1}^l [a(x_i) = k] \|x_i - c_k\|^2 = 0$$

$$\sum_{i=1}^l [a(x_i) = k] (x_i - c_k) = 0 \implies c_k = \frac{\sum_{i=1}^l [a(x_i) = k] x_i}{\sum_{i=1}^l [a(x_i) = k]} - \text{точка экстремума}$$

$$\frac{d^2 f(c_k)}{dc_k^2} = \sum_{i=1}^l [a(x_i) = k] > 0 \implies c_k - \text{точка минимума}$$